

Prompts: antes y después

Informe de implementación y verificación - 6 de octubre de 2026

Qué se aplicó

Queda activo el retiro de un ejemplo de formato JSON que repetía el esquema estricto del extractor: 2.251 caracteres menos cuando se utiliza el bloque semántico completo. La ruta financiera compacta no cambia. Se probó una deduplicación adicional del contexto, pero se dejó INACTIVA porque una respuesta mezcló áreas entre categorías. No se cambiaron modelos ni reglas comerciales.

Aspecto	Antes	Ahora
Formato del extractor	Esquema estricto y ejemplo JSON escrito dentro de las instrucciones.	El mismo esquema estricto y una indicación breve de seguirlo.
Estado compartido	Contexto reducido y referencias del catálogo ya existentes.	Se conserva el comportamiento anterior. Las referencias adicionales probadas NO están activadas.
Conflictos y datos ausentes	Se mantenían valores diferentes, null, false y cero.	Se mantienen. Una referencia nunca significa dato ausente.
Validación y memoria	Evidencia canónica completa y controles de acciones.	Sin recortes: la proyección solo afecta la entrada del modelo.
Modelos y revisión	Modelos configurados y interruptor global de revisión.	Se conservan ambos. No se fuerza activar ni desactivar la revisión.

Se conserva byte por byte la prosa semántica posterior al ejemplo retirado y el esquema estricto completo. No se truncan mensajes ni se eliminó evidencia. El ahorro es moderado: no implica que cada mensaje cueste menos ni que salga siempre más rápido.

Reglas que se conservan

Caso	Comportamiento que permanece
Saludos y presentación	Variantes y errores de escritura; apertura, nombre y residencia según el estado del lead.
Perfil incompleto	No inventar apellido, residencia o confirmación. Las reglas existentes deciden cuándo volver a pedir datos.
Cinco dormitorios sin oferta	Presentar alternativas verificadas de tres con sus diferencias y pedir aceptación antes de avanzar.
Precios de alternativas	Resolver “¿qué precios tienen?” sobre las opciones propuestas; preguntar no acepta la alternativa.
Nueva intención o negación	Permitir cambiar de tema; no convertir rechazo, duda o hipótesis en consentimiento.
Selección progresiva	Categoría y planta primero; después opciones de esa planta. Una sola opción compatible se presenta con características y tour 360 autorizado.
Cantidades y superficies	Personas y dormitorios se separan. Rangos, mínimos, extremos y áreas se sustentan en unidades verificadas.
Presupuesto	Mantener estimaciones tentativas y distinguir precio total, aporte inicial y crédito solicitado.
JEP y Banco Pichincha	Conservar la entidad elegida, consentimiento y requisitos pendientes. No sustituirlos por una consulta informativa.
Datos financieros	Nombre legal completo, cédula y perfil laboral se validan sin completar información por suposición.
Entrega y políticas	Respetar configuración: fecha confirmada, estimación o ausencia de fecha; reglas comerciales y condiciones habilitadas.
Respuesta y continuación	Contestar la consulta actual, enlazarla con el siguiente paso y conservar una pregunta pertinente.
Materiales y ubicación	Usar enlaces autorizados y estado de materiales enviados; conservar las condiciones existentes para dirección y mapa.
Reservas, citas y asesor	Exigir operaciones reales antes de afirmar confirmación, envío o asignación. No derivar por una consulta informativa normal.
Consultas compuestas	Retener todas las peticiones y su procedencia. Mantener opt-out, controles de revisión y recuperación técnica.
Embeddings y alcance	Búsqueda exacta y semántica siguen su ruta. Candidatas semánticas no prueban totales, extremos ni ausencia en todo el proyecto.

Resultados de las pruebas

Las pruebas son aisladas: no escriben conversaciones ni envían mensajes a WhatsApp o Kommo. Los valores del conjunto de evaluación son sintéticos y no se publican como condiciones del proyecto.

Verificación	Resultado
Regresión amplia, sin duplicar archivos	122 archivos; 1523 pruebas: 1477 aprobadas, 46 fallidas.
Control con el código anterior	1478 pruebas: 1432 aprobadas, 46 fallidas. El conjunto de fallos coincide con el actual.
Pruebas nuevas de reducción	40 aprobadas: equivalencia de datos, ciclos, conflictos, esquema, 18 etapas con inventario completo/incompleto y protección del contexto de producción. Otras 5 verifican las fichas y criterios de la evaluación.
Comparación real con el modelo	98 llamadas en total. Extractor: 32 de 32 aprobadas, sobre 16 escenarios. Candidato de contexto: 20 llamadas válidas al redactor, con 1 fallo de relación categoría-área; se descartó su activación.
Reglas y formato	La prosa semántica posterior al ejemplo de JSON se conserva byte por byte; el esquema de respuesta antes/después es idéntico.
Compilación y lint	TypeScript aprobado / Build aprobado / Lint aprobado

Lo que las pruebas amplias revelaron

Las 46 pruebas que fallan ya fallaban con la revisión anterior: 42 en `integrations.test.cjs`, 3 en `unit-alternatives.test.cjs` y 1 en `financing-review-action.test.cjs`. Hay expectativas de texto y contratos de mocks antiguos (por ejemplo, `validateReply`), y diferencias de flujo que necesitan auditoría. No se cambiaron ni omitieron esas pruebas para obtener un resultado verde; no se afirma que sean 46 fallos de mensajes reales ni que todos sean simples fallos del test.

Qué cubrió la comparación con IA

Referencias a precios y tamaños de propuestas; aceptar o rechazar alternativas; cambiar de tema; personas frente a dormitorios; mínimo de dormitorios; presupuesto tentativo; elección de JEP o Pichincha; identidad parcial; consultas compuestas; visita negada; asesor explícito; rechazo de mensajes; presentación con errores de escritura. En el redactor: aperturas, precios/planta, orientación familiar y reconocimiento de perfil.

Son escenarios representativos, no todas las conversaciones posibles. Una comparación por escenario no determina una tasa estadística de errores. Las pruebas con referencias verifican conservación de información, pero el modelo aún puede interpretar mal esa información.

Costo, alcance y reversión

Medida de la muestra real	Antes	Después	Diferencia
Caracteres de instrucciones	714416	678400	-5.0 %
Caracteres de contexto	18676	18676	0.0 %
Caracteres de esquema	203056	203056	0.0 %
Tokens de entrada API	188426	179386	-4.8 %
Entrada en caché API	162304	161152	-0.7 %
Tokens de salida API	14941	14710	-1.5 %
Costo calculado (USD)	0.2529	0.2347	-7.2 %
Duración media API (s)	8.20	10.59	29.1 %

La tabla mide únicamente el recorte aprobado del extractor. Tokens y caché provienen de usage en la API; los dólares se calculan con las tarifas registradas, no son una factura devuelta por la API. Gasto total de todas las evaluaciones: USD 1.6909.

Se alternó el orden antes/después. La caché y la variación de salida afectan el costo observado; la latencia también depende del servicio. La diferencia de tamaño de entrada sí se atribuye a este recorte porque cada par usa el mismo contexto, modelo y esquema.

Límites y condiciones para volver atrás

Este cambio no busca solucionar todas las causas del costo: los prompts de reglas siguen siendo grandes, y las reescrituras o recuperaciones pueden dominar una ejecución. Tampoco cambia el cron, la agrupación de mensajes ni la selección de embeddings; conserva los ajustes anteriores.

Validación y reproducción

Recorte descartado por calidad

Una respuesta del candidato mezcló los 120,83 m² del departamento con los 142,09 m² del penthouse. Tres repeticiones por versión pasaron los criterios automáticos; en la lectura manual también apareció “balcones” cuando la ficha solo acreditaba área exterior. Estos resultados no justifican activar el recorte cuando la prioridad es conservar la calidad.

Control y reversión

Si aparece una regresión nueva, conserve su ejecución y compare el mismo estado completo. La deduplicación ampliada solo funciona con `deduplicateSharedState=true`: ninguna llamada de producción lo activa. Para volver al formato anterior del extractor, restaure `turn-semantic.ts` desde la revisión base en una nueva revisión de código, preservando las correcciones comerciales previas.

Base: 392fd351dc9271a2f6730ead7bed2af4fc757864. `shared-turn-state-v1` es un candidato experimental INACTIVO. Archivos: `turn-semantic.ts` y `turn-prompt-context.ts`. No se sobrescribieron la configuración editable del negocio ni los prompts publicados en la base de datos.

Reproducción

`npm run test:prompt-compaction`; `node scripts/test-automation-regressions.cjs`; `npm run eval:prompt-compaction` (captura sin llamadas). Para comparar la IA: `--live --max-calls 46 --max-usd 3. --experimental-shared-state` evalúa el candidato descartado, sin activarlo en producción. Solo se permite la API de Responses y se limita el gasto.

Referencias oficiales: developers.openai.com/api/docs/guides/prompt-engineering y developers.openai.com/api/docs/guides/structured-outputs. El esquema asegura la forma; conservar calidad exige evaluar el comportamiento.